

Regresión Lineal Múltiple

Rendimiento de combustible de automóviles

Jose Santiago Cedeño

29 de mayo de 2026

1. Introducción

El rendimiento de combustible es una variable crítica en la industria automotriz. Comprender qué factores lo afectan permite diseñar vehículos más eficientes. En este trabajo se aplica un modelo de regresión lineal múltiple al conjunto de datos *Auto MPG* (UCI Machine Learning Repository), que contiene información de 398 vehículos fabricados entre 1970 y 1982. El objetivo es modelar el consumo en millas por galón (mpg) a partir de variables como el número de cilindros, cilindrada, potencia, peso, aceleración, año del modelo y origen.

2. Descripción de la base de datos

La base de datos original incluye las siguientes variables:

- **mpg**: Rendimiento (millas por galón) – variable dependiente.
- **cylinders**: Número de cilindros.
- **displacement**: Cilindrada del motor (pulgadas cúbicas).
- **horsepower**: Potencia (caballos de fuerza).
- **weight**: Peso del vehículo (libras).
- **acceleration**: Tiempo de aceleración de 0 a 60 mph (segundos).
- **model_year**: Año del modelo (70 = 1970, 71 = 1971, etc.).
- **origin**: Origen del vehículo (1 = EE. UU., 2 = Europa, 3 = Japón).

Después de eliminar 6 registros con valores faltantes en la variable **horsepower**, se trabajó con 392 observaciones. La Tabla 1 muestra las estadísticas descriptivas.

Cuadro 1: Estadísticas descriptivas de las variables numéricas

Variable	Media	Desv. estándar	Mínimo	25 %	Mediana	75 %	Máximo
mpg	23.45	7.81	9.00	17.00	22.75	29.00	46.60
cylinders	5.47	1.71	3.00	4.00	4.00	8.00	8.00
displacement	194.41	104.64	68.00	105.00	151.00	275.75	455.00
horsepower	104.47	38.49	46.00	75.00	93.50	126.00	230.00
weight	2977.58	849.40	1613.00	2225.25	2803.50	3614.75	5140.00
acceleration	15.54	2.76	8.00	13.78	15.50	17.03	24.80
model_year	75.98	3.68	70.00	73.00	76.00	79.00	82.00
origin	1.58	0.81	1.00	1.00	1.00	2.00	3.00

3. Metodología

Se planteó un modelo de regresión lineal múltiple:

$$mpg = \beta_0 + \beta_1 \cdot cylinders + \beta_2 \cdot displacement + \beta_3 \cdot horsepower + \beta_4 \cdot weight + \beta_5 \cdot acceleration + \beta_6 \cdot model_year + \beta_7 \cdot origin + \varepsilon$$

El modelo se ajustó mediante mínimos cuadrados ordinarios (OLS) usando la librería `statsmodels` de Python. Posteriormente se verificaron los supuestos:

- Normalidad de residuos (prueba de Shapiro-Wilk y gráfico Q-Q).
- Independencia (estadístico de Durbin-Watson).
- Multicolinealidad (Factor de Inflación de la Varianza, VIF).

4. Análisis exploratorio de datos

4.1. Matriz de correlación

La Figura 1 muestra la matriz de correlación entre las variables numéricas. Se observa una fuerte correlación negativa entre `mpg` y `weight` (-0.83), `displacement` (-0.81) y `horsepower` (-0.78). También hay alta correlación entre las variables predictoras (ej. `displacement` y `weight`: 0.93), lo que anticipa problemas de multicolinealidad.




Figura 1: Matriz de correlación entre las variables numéricas

4.2. Diagrama de pares (pairplot)

La Figura 2 presenta los diagramas de dispersión entre las variables clave. Se aprecia una tendencia decreciente de `mpg` con respecto a `weight`, `displacement` y `horsepower`, así como una tendencia creciente con `model_year`. La nube de puntos muestra relaciones aproximadamente lineales, aunque con cierta heterocedasticidad.




Figura 2: Diagrama de pares para las principales variables

5. Resultados del modelo de regresión

5.1. Resumen del modelo

El ajuste del modelo produjo los resultados mostrados en la Tabla 2. El coeficiente de determinación $R^2 = 0,821$ indica que el modelo explica el 82.1 % de la variabilidad del rendimiento de combustible. El R^2 ajustado es 0.818, similar, lo que sugiere que las variables incluidas son relevantes. El estadístico F (252.4) con un p-valor prácticamente nulo ($2,04 \times 10^{-139}$) confirma la significancia global del modelo.

Cuadro 2: Coeficientes del modelo e intervalos de confianza al 95 %

Variable	Coeficiente	Error estándar	p-valor	IC 95 %
const	-17.2184	4.644	0.000	(-26.350, -8.087)
cylinders	-0.4934	0.323	0.128	(-1.129, 0.142)
displacement	0.0199	0.008	0.008	(0.005, 0.035)
horsepower	-0.0170	0.014	0.220	(-0.044, 0.010)
weight	-0.0065	0.001	0.000	(-0.008, -0.005)
acceleration	0.0806	0.099	0.415	(-0.114, 0.275)
model_year	0.7508	0.051	0.000	(0.651, 0.851)
origin	1.4261	0.278	0.000	(0.879, 1.973)

5.2. Interpretación de coeficientes significativos ($p < 0.05$)

- **Peso (weight):** Por cada libra adicional, el rendimiento disminuye en 0.0065 mpg. Equivalentemente, un aumento de 1000 libras reduce el rendimiento en 6.5 mpg. El intervalo de confianza es completamente negativo, confirmando un efecto perjudicial.
- **Año del modelo (model_year):** Cada año más nuevo incrementa el rendimiento en 0.75 mpg. Es el coeficiente positivo más relevante, indicando mejoras tecnológicas en eficiencia.
- **Origen (origin):** Los vehículos de origen europeo o japonés (códigos 2 y 3) rinden en promedio 1.43 mpg más que los americanos (código 1), manteniendo las demás variables constantes.
- **Cilindrada (displacement):** Presenta un coeficiente positivo (0.02), lo cual es contraintuitivo (mayor cilindrada debería aumentar el consumo). Esto puede deberse a la alta multicolinealidad con el peso y el número de cilindros, distorsionando el signo.

Las variables `cylinders`, `horsepower` y `acceleration` no resultaron estadísticamente significativas ($p > 0.05$).

5.3. Coeficientes estandarizados (betas)

Para comparar la magnitud de los efectos, se calcularon los coeficientes estandarizados (Tabla 3). La variable que más afecta el consumo (en valor absoluto) es **weight** ($\beta = -5,49$), seguida de **model_year** ($\beta = 2,76$). Esto confirma que el peso tiene el impacto más fuerte sobre el rendimiento.

Cuadro 3: Coeficientes estandarizados (betas)

Variable	β
weight	-5.492
model_year	2.762
displacement	2.079
origin	1.147
acceleration	0.222
horsepower	-0.652
cylinders	-0.841

6. Verificación de supuestos

6.1. Normalidad de residuos

La prueba de Shapiro-Wilk arrojó un estadístico de 0.9766 y un p-valor de 6×10^{-6} , lo que rechaza la hipótesis de normalidad ($p < 0,05$). El gráfico Q-Q (Figura 3) muestra desviaciones en los extremos, especialmente en la cola superior (puntos por encima de la línea). La no normalidad puede afectar la validez de los intervalos de confianza y los p-valores, aunque con una muestra de 392 observaciones el teorema del límite central mitiga parcialmente el problema.




Figura 3: Gráfico Q-Q de los residuos

6.2. Independencia de residuos

El estadístico de Durbin-Watson fue 1.309, inferior al valor ideal de 2. Esto indica **autocorrelación positiva** en los residuos. Dado que los datos no están ordenados temporalmente (aunque sí hay un año de modelo), la autocorrelación podría deberse a la omisión de alguna variable relevante o a la estructura de los datos. Es recomendable revisar el modelo e incluir términos de interacción o transformaciones.

6.3. Multicolinealidad

Los factores de inflación de varianza (VIF) se muestran en la Tabla 4. Casi todas las variables presentan VIF extremadamente altos (> 10), y en particular **weight** (139.5), **cylinders** (117.7), **model_year** (115.8) y **displacement** (96.9). Esto confirma **multicolinealidad severa**, que explica el signo ilógico de **displacement** y la inestabilidad de los coeficientes. Se recomienda eliminar variables redundantes (por ejemplo, **displacement** o **cylinders**) o utilizar técnicas de regularización (ridge regression).

Cuadro 4: Factores de inflación de varianza (VIF)

Variable	VIF
cylinders	117.71
displacement	96.91
horsepower	67.07
weight	139.45
acceleration	69.70
model_year	115.79
origin	8.47

7. Discusión de las preguntas planteadas

7.1. ¿Qué variable afecta más el consumo?

Según los coeficientes estandarizados, el **peso (weight)** es la variable con mayor impacto en el rendimiento de combustible ($\beta = -5.49$). Aunque el signo es negativo, su magnitud indica que pequeños cambios en el peso producen grandes cambios en mpg. En segundo lugar, el **model_year** también es muy influyente.

7.2. ¿El peso influye positiva o negativamente?

Influye **negativamente**: a mayor peso, menor mpg (más consumo). El coeficiente es estadísticamente significativo y su intervalo de confianza no contiene el cero.

7.3. ¿Los carros más nuevos consumen menos combustible?

Sí. El coeficiente de **model_year** es positivo (0.75), lo que significa que por cada año más reciente, el rendimiento aumenta en promedio 0.75 mpg, es decir, consumen menos combustible.

8. Conclusiones

El modelo de regresión lineal múltiple logra explicar el 82% de la variabilidad del rendimiento de combustible en automóviles, con el peso y el año del modelo como los predictores más importantes. Sin embargo, se identificaron problemas graves de multicolinealidad que distorsionan algunos coeficientes (como el de `displacement`) y pueden afectar la inferencia. Además, los residuos no siguen una distribución normal y presentan autocorrelación, lo que sugiere que el modelo podría mejorarse. A pesar de estas limitaciones, las respuestas a las preguntas clave son robustas: el peso afecta negativamente al consumo, y los automóviles más nuevos son más eficientes. Este estudio proporciona una base sólida para profundizar en el análisis de eficiencia vehicular.

Entregables asociados

- Código Python completo (regresión, pruebas de supuestos, gráficos).
- Base de datos limpia en formato CSV (`auto_mpg_limpio.csv`).
- Gráficas: matriz de correlación, pairplot, Q-Q plot, histograma de residuos.
- Este informe en PDF (compilado desde LaTeX).